Математические модели процессов отбора

Лекция 4.

Понятие отбора

Отбор и поисковые методы оптимизации

Дополнительный источник

F. Yang, H. Jiang, L. Lyu, “Multi-strategy fusion improved Northern Goshawk optimizer is used for engineering problems and UAV path planning,“ Sci Rep 14, 23300 (2024).

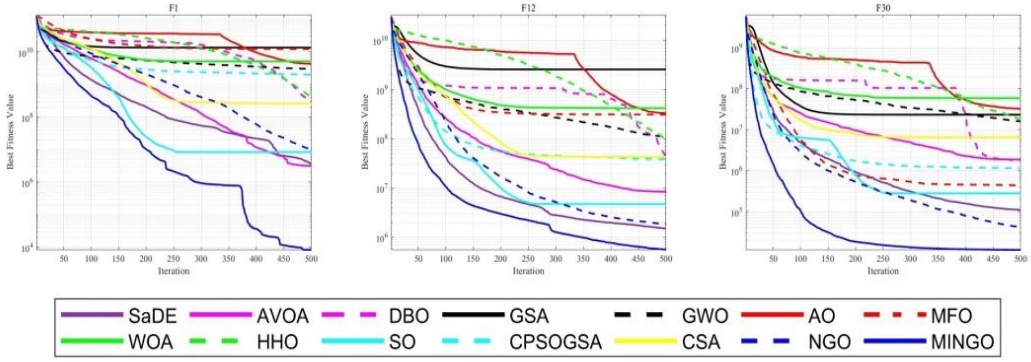

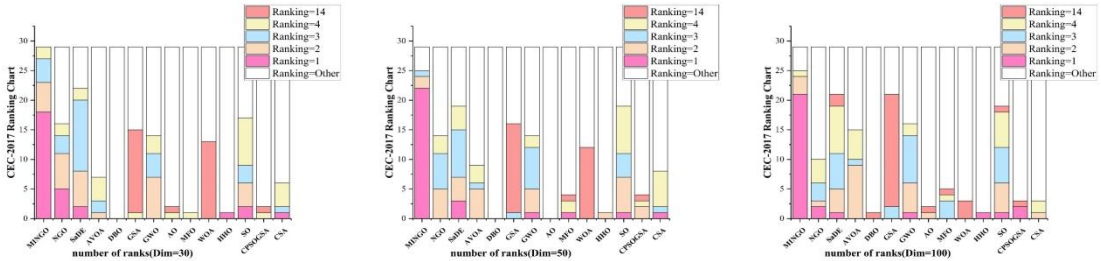

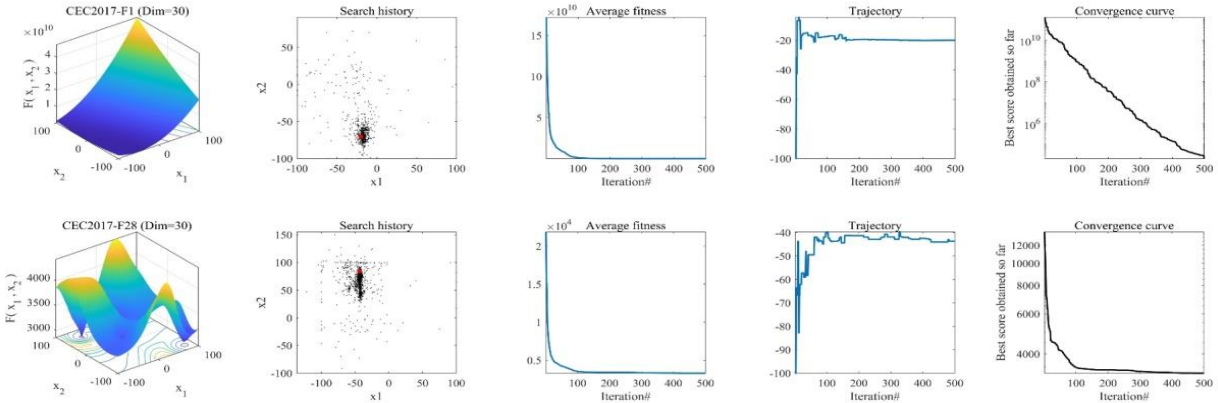

Примеры отбора. Модель Вольтерра-Лотки. Нормировка

$$x_i' = a_i x_i - x_i \sum_{j=1}^{n} a_j x_j \qquad \xi'_i = a_i \xi_i \qquad \xi_i(t) = x_i^0 \exp\left(a_i (t - t_0)\right)$$

$$x'_i(t) = \frac{\xi_i' \sum_{j=1}^{n} \xi_j - \xi_i \sum_{j=1}^{n} \xi_j'}{\left(\sum_{j=1}^{n} \xi_j\right)^2} = \frac{a_i \xi_i}{\sum_{j=1}^{n} \xi_j} - \frac{\xi_i}{\sum_{j=1}^{n} \xi_j} \sum_{j=1}^{n} \frac{a_j \xi_j}{\sum_{k=1}^{n} \xi_k} \qquad x_i(t) = \frac{\xi_i}{\sum_{j=1}^{n} \xi_j}$$

$$x_i(t) = \frac{x_i^0 \exp\left(a_i (t - t_0)\right)}{\sum_{j=1}^{n} x_j^0 \exp\left(a_j (t - t_0)\right)}$$

- $a_1 > a_2 > \ldots a_n \qquad x_1(t) \to 1,\ x_i(t) \to 0$

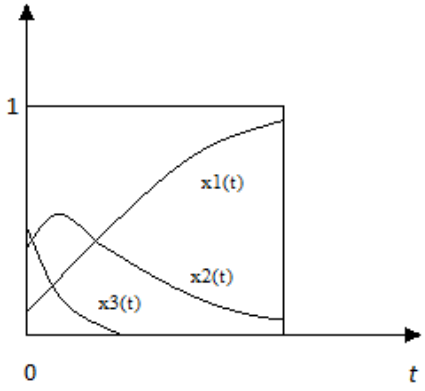

Разностная модель Вольтерра - Лотки

$$\Delta x_i = \frac{a_i x_i - x_i \sum_{j=1}^{n} a_j x_j}{\sum_{j=1}^{n} a_j x_j \Delta t + 1} \Delta t$$

$$\Delta z_i = a_i z_i \Delta t$$

$$z_i(t_k) = x_i(t_0)(1 + a_i \Delta t)^k$$

$$x_i = \frac{z_i}{\sum_{j=1}^{n} z_j}$$

$$x_i(t_k) = \frac{x_i(t_0)(1 + a_i \Delta t)^k}{\sum_{j=1}^{n} x_j(t_0)(1 + a_j \Delta t)^k}$$

$$z_i(t_0) = 1/n, \quad \Delta t = 1$$

$$x_i(t_k) = \frac{(1 + a_i)^k}{\sum_{j=1}^{n} (1 + a_j)^k}$$

$$x_i(t_k) = \frac{(F(z_i))^k}{\sum_{j=1}^{n} (F(z_j))^k}$$

Связь SoFA с биологическими моделями отбора

- **Метод SoFA**
- Пусть сделано *k-1* испытание: имеется *k-1* точка $z_1,\ldots,z_{k-1}$ и вычислены соответствующие значения функции $F(z_1),\ldots F(z_{k-1})$.
- **Построение популяции**: Вычисляются значения

$$\rho(z_i) = \frac{F^{\psi(k)}(z_i)}{\sum_{j=1}^{k-1} F^{\psi(k)}(z_j)}$$

- Здесь $\psi(k)$ – заранее выбранная функция настройки, $\psi(k)\to\infty$ при $k\to\infty$.
- Значения $\rho(z_i)$ сравниваются с пороговым параметром γ и определяются характеристические значения принадлежности к популяции μ_{ik}:

$$\mu_{ik}=1, \quad \text{если } \rho(z_i)>\gamma; \qquad \mu_{ik}=0, \quad \text{если } \rho(z_i)<\gamma.$$

- Популяцию на *k*-м шаге образует подмножество точек испытаний, для которых $\mu_{ik}=1$

- Различные шкалы времени $\psi(k)$

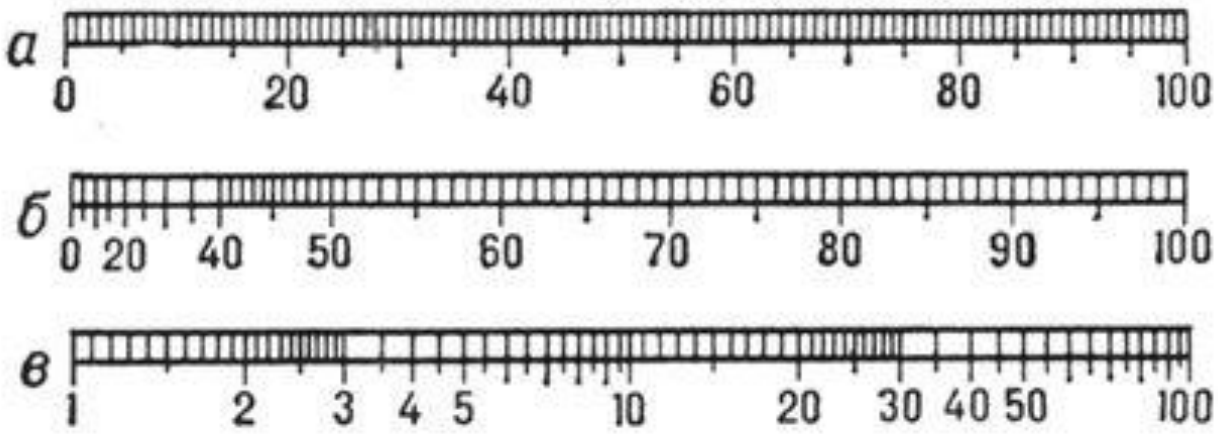

Метод SoFA – Survival of the Fittest Algorithm

- **2. Выбор опорной точки**: Из точек популяции выбирается опорная точка $w_k = (w_{1k}, \ldots, w_{nk})$ с вероятностями ($\psi(k) \to \infty$ при $k \to \infty$)

$$\frac{F^{\psi(k)}(z_i)}{\sum_{j=1}^{k-1} \mu_{jk} F^{\psi(k)}(z_j)} \qquad (1)$$

- **3. Генерация новой точки испытания.** На основе опорной точки выбирается точка следующего испытания z_k. Каждая j-ая координата z_{jk} этой точки выбирается из отрезка $[a_j, b_j]$ случайно с нормальным распределением вероятности

$$A_{jk} \exp\left(-\frac{(z_{jk} - w_{jk})^2}{\sigma_k} \right) \qquad (2)$$

- Здесь σ_k – дисперсия, удовлетворяющая условию $\sigma_k \to 0$ при $k \to \infty$.
- Константы A_{jk} выбираются так, чтобы выполнялось условие нормировки.
- **4. Расчет значения функции.** Далее вычисляется $F(z_k)$
  И процесс повторяется.

III. ALGORITHM

A. Preparatory stage of the algorithm: initial population

Initially, m points (agents) $z^1, ..., z^m$ are randomly and uniformly selected from the hyperparallelepiped Π. The function values $F(z^1), ..., F(z^m)$ are calculated for these agents. These agents constitute the initial population. Then we set $\mu(i, m+1) = 1$ for $i = \overline{1, m}$.

B. Main stages of the algorithm: population evolution

At each k-th step beyond the initial m steps ($k > m$), a new agent $z^k = (z_1^k, ..., z_n^k)$ is selected in Π through a series of operations. The first operation involves identifying the agent $z^{k*} = (z_1^{k*}, ..., z_n^{k*})$ with the highest objective function value F within the population. This agent is determined by the following equation:

$$F(z^{k*}) = \max_{j=\overline{1,k-1}} \left(\mu(j,k) \cdot F(z^j)\right). \tag{2}$$

Next, a reference agent w^k is randomly selected from the population with the selection probability for each agent determined by the following probability distribution:

$$p_j^k = \frac{\left(F(z^j)\right)^{\phi(k)}}{\sum_{l=1}^{k-1} \left(\mu(l,k)\left(F(z^l)\right)^{\phi(k)}\right)}. \tag{3}$$

In addition to the reference agent, two more agents, v^k and u^k, are selected from the population using the same probability distribution. Formula (3) corresponds to the dynamics of the normalized number of competing species in a community that satisfies the Volterra-Lotka hypotheses. In this case, the value $F(z^j)$ plays the role of the fitness of the j-th species – the reproduction coefficient in favorable conditions.

Once the agents are selected, an anisotropic mutation is applied to each gene (coordinate) of the agent. The mutation type, either strong or weak, is determined by comparing a uniformly distributed random variable ξ_i^k (drawn from the interval [0, 1]) with the parameter G. If $\xi_i^k < G$, a strong mutation is applied to the ith gene; otherwise, a weak mutation is performed.

After determining the mutation type, the scale parameter σ_{ik} and the shift parameter m_i^k of the Cauchy distribution are calculated for the mutation of each i-th gene.

- for the strong mutation:

$$m_i^k = w_i^k + H(k)\left(z_i^{k*} - w_i^k\right) + H(k)\left(v_i^k - u_i^k\right); \tag{4}$$

$$\sigma_{ik} = \zeta(k); \tag{5}$$

- for the weak mutation:

$$m_i^k = w_i^k; \tag{6}$$

$$\sigma_{ik} = \zeta(k+N). \tag{7}$$

Each gene z_i^k of the new agent is randomly selected from a Cauchy distribution defined over the interval $[a_i^L, a_i^R]$, with the probability density function:

$$f_{cauchy}(z_i^k) = B_{ik} \frac{\sigma_{ik}}{(z_i^k - m_i^k)^2 + \sigma_{ik}^2}, \tag{8}$$

the constant B_{ik} is determined based on the normalization condition:

$$B_{ik} = \left(\int_{a_i^L}^{a_i^R} \frac{\sigma_{ik}}{(z_i^k - m_i^k)^2 + \sigma_{ik}^2} dz_i^k\right)^{-1}. \tag{9}$$

After generating the new agent z^k, its objective function value $F(z^k)$ is computed. Then the population for the next $k+1$ step is formed according to the following rule:

$$\mu(j, k+1) = \begin{cases} 1, & \text{if } \dfrac{\left(F(z^j)\right)^{\phi(k)}}{\sum\limits_{l=1}^{k} \left(F(z^l)\right)^{\phi(k)}} > \gamma, \quad j = \overline{1,k} \\ 0, & \text{otherwise} \end{cases}.$$

The process is then repeated for subsequent steps.

C. Final stage of the algorithm: obtaining the result

In the simplest case, the algorithm stops when a specified number of steps is exhausted.

The solution to the problem is then determined by identifying the best point, denoted as j^*, where:

$$j^* = arg \max_j F(z^j),$$

the optimal point is denoted as z^{j^*}, with $F(z^{j^*})$ representing the value of the objective function at this point.

Отбор (селекция) в генетическом алгоритме

- На этапе отбора нужно из всей популяции выбрать определённую её долю, которая останется «в живых» на этом этапе эволюции. Остальные особи погибают. Вероятность выживания особи зависит от значения функции приспособленности. Доля выживших s является параметром генетического алгоритма, задается заранее.

Разные способы отбора

- Турнирная селекция
- Метод ранжирования
- Метод рулетки

$$p(z_i)=F(z_i)/\sum_{j=1}^{N} F(z_j)$$

Задача оптимизации

Математически задача оптимизации ставится следующим образом. Пусть на множестве M, состоящем из элементов x произвольной природы, определен функционал $J[x]$. Требуется найти элемент $x^* \in M$, на котором значение функционала J будет наибольшим или наименьшим:

$$J[x^*] = \max_{x \in M} J[x] \quad \text{или} \quad J[x^*] = \min_{x \in M} J[x].$$

Поскольку отыскание максимума некоторого функционала $J[x]$ равносильно поиску минимума функционала $-J[x]$, то, не уменьшая общности, можно рассматривать только задачу минимизации.

$$J[x] \to \min, \quad x \in M.$$

Метод перебора (для многомодальных функций)

- Разбиение отрезков на равные части и проверка каждой из точек, т.е. расчет или сравнение производных

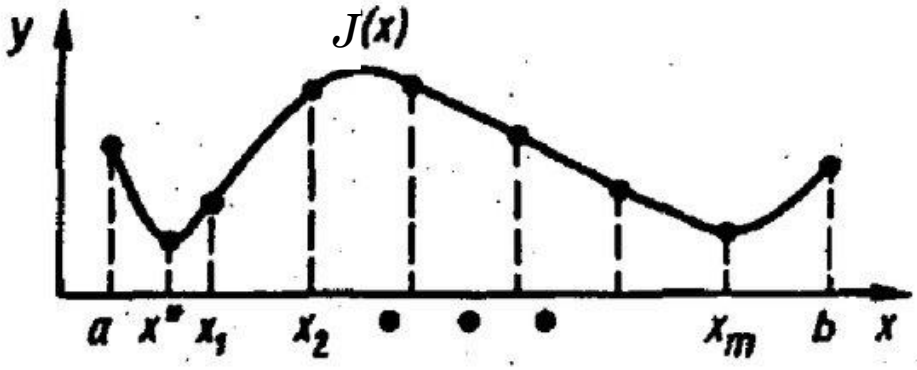

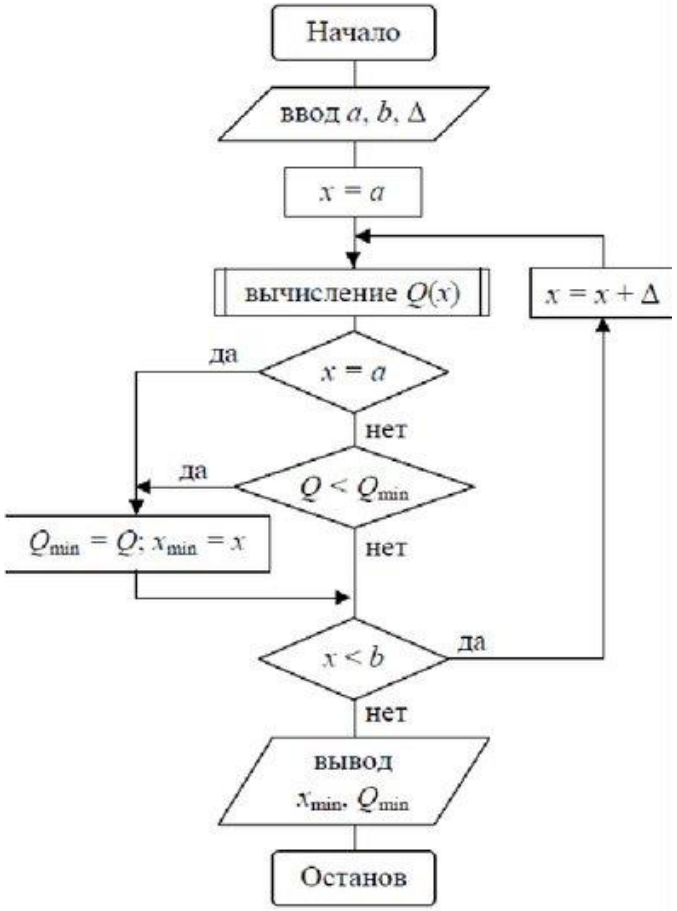

Динамика вероятности

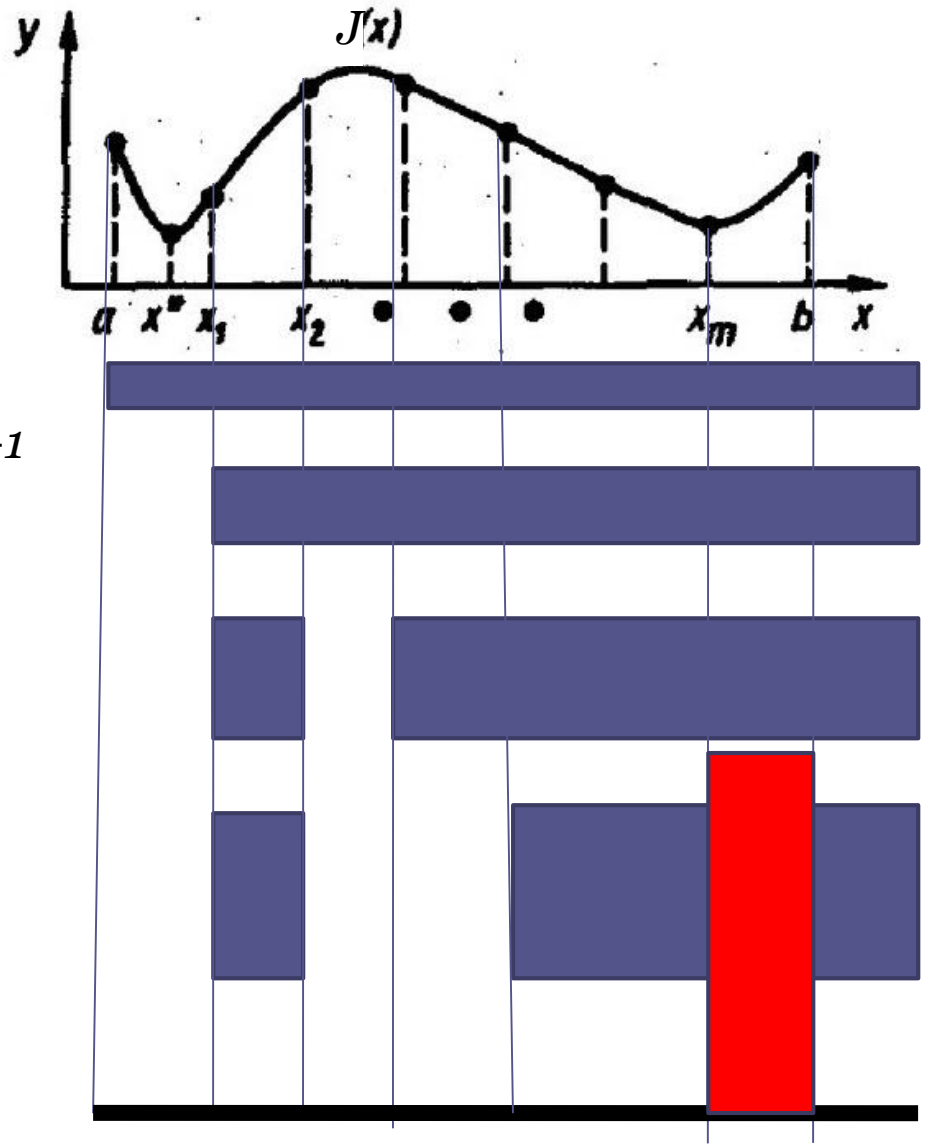

- I: $p_i=1/(m+2)$, $i=0,1,2,\ldots,m,m+1$
- II: $p_0=0$, $p_i=1/(m+1)$, $i=1,2,\ldots,m,m+1$
- III: $p_0=0$, $p_1=1/m$, $p_2=0$,
  $p_i=1/m$, $i=3,\ldots,m+1$
- IV: $p_0=0$, $p_1=1/(m-1)$, $p_2=0$, $p_3=0$,
  $p_i=1/(m-1)$, $i=4,\ldots,m+1$

  …
- M+2: $p_i=0$, $i=0,\ldots,m-1$,
  $p_m=1$, $p_{m+1}=0$

- $p_i \to 0$, $p_m \to 1$

Метод Монте-Карло

- *Всюду плотная последовательность*

- $p_i \to 0, p_1 \to 1$

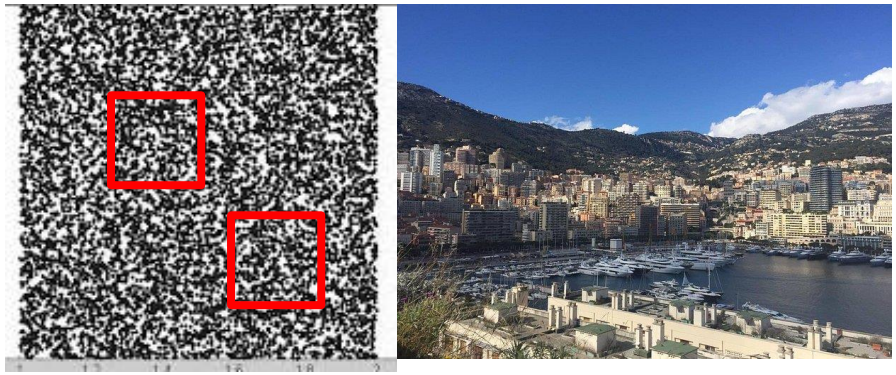

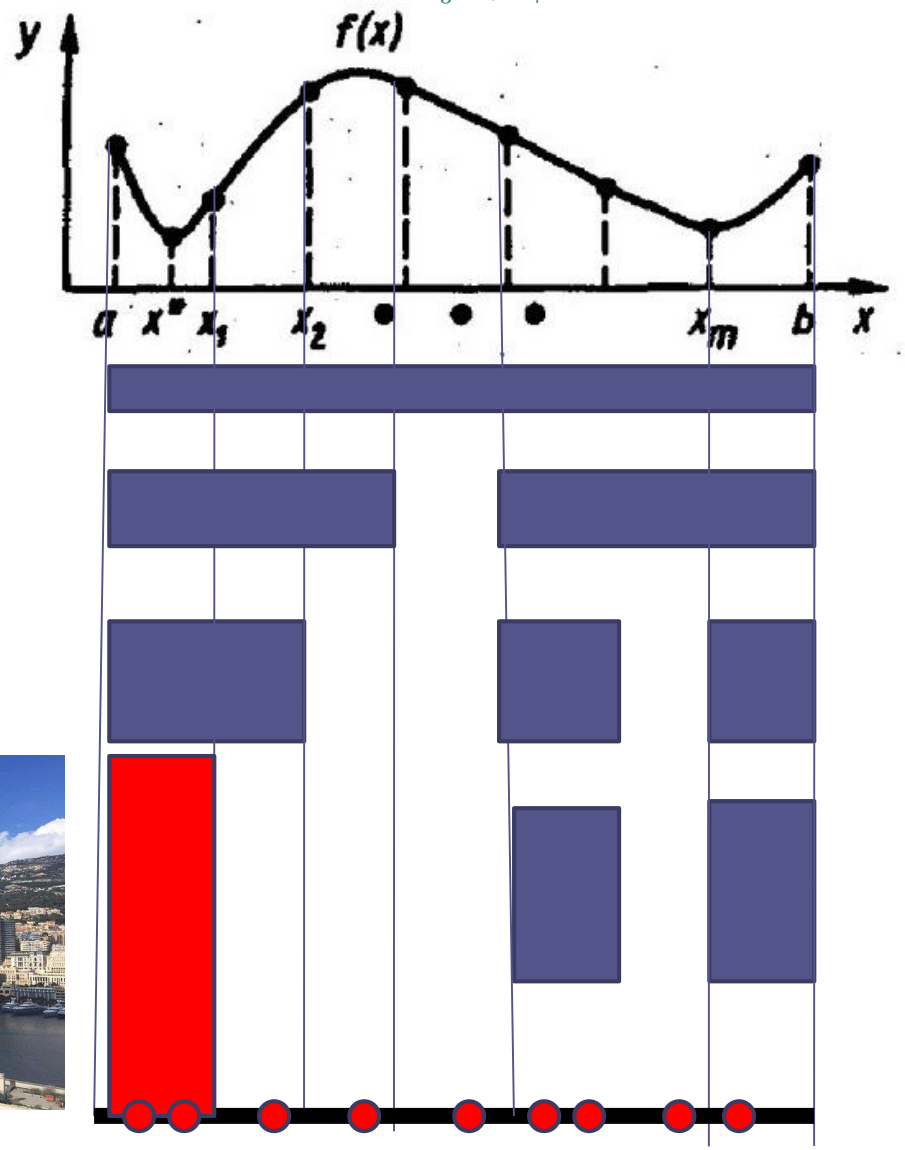

Концентрация распределения вероятности около точки максимума

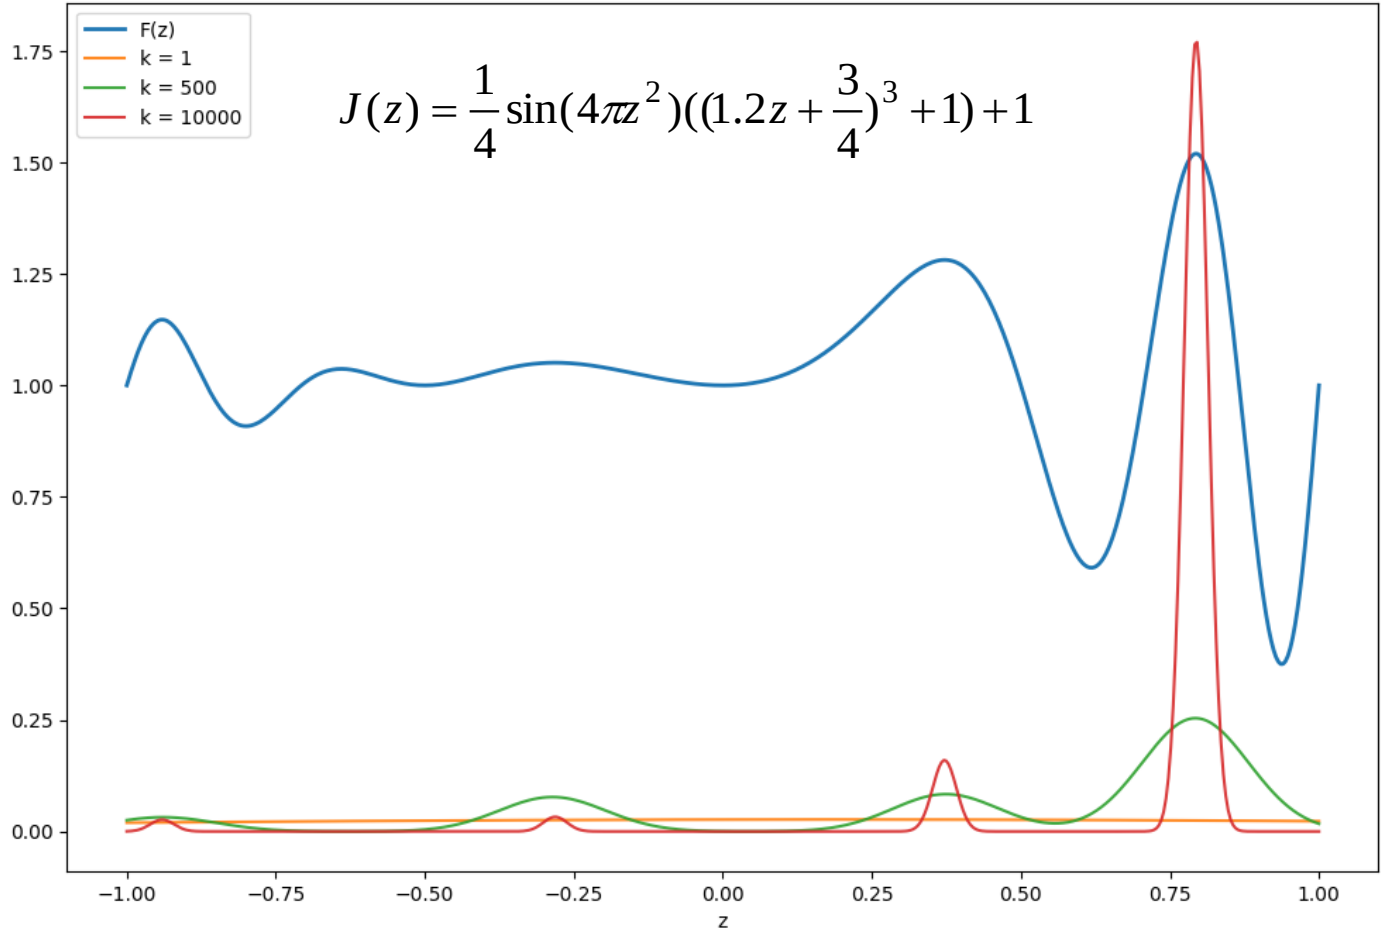

Концентрация распределения в оптимизации

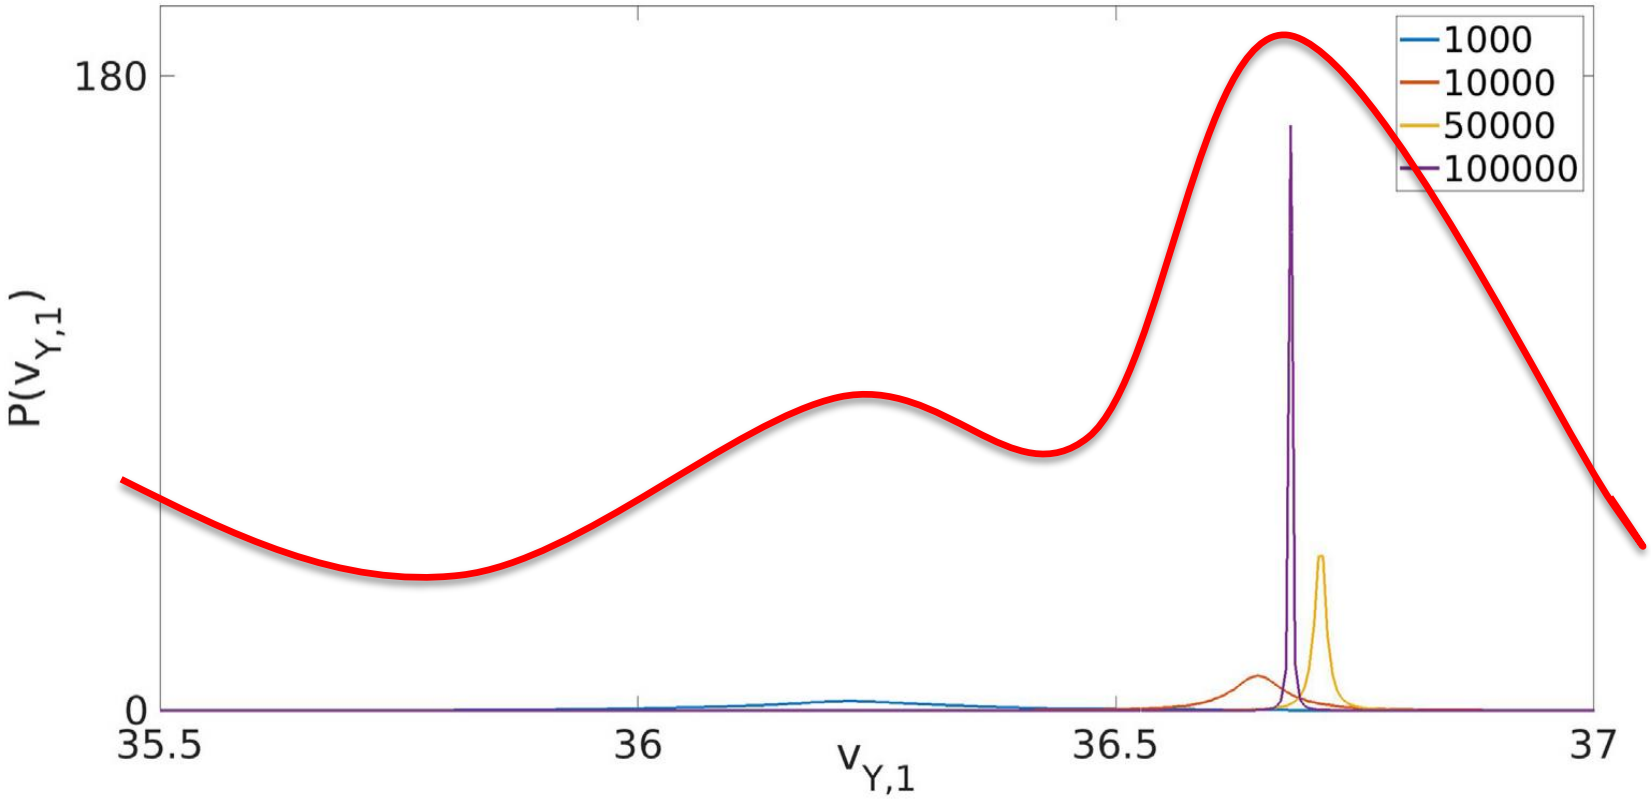

Информация связана с концентрацией (локализацией) распределения показателя присутствия (вероятностей) на множестве альтернатив